

Lab02

Tiago Perroni

```
library(dplyr)
```

Anexando pacote: 'dplyr'

Os seguintes objetos são mascarados por 'package:stats':

```
filter, lag
```

Os seguintes objetos são mascarados por 'package:base':

```
intersect, setdiff, setequal, union
```

```
library(readr)  
library(ggplot2)
```

1.

Para calcular a proporção global de voos atrasados acumulando dados lote a lote sem carregar tudo na memória, não podemos apenas tirar a média das médias dos lotes.

As estatísticas suficientes necessárias para cada grupo (Dia, Mês e Cia. Aérea) são:

n_total: O número total de voos no grupo (contagem total de observações válidas).

n_atrasos: O número de voos do grupo que apresentaram atraso na chegada maior que 10 minutos (ARRIVAL_DELAY > 10).

2 e 3.

```

getStats <- function(input, pos) {
  input %>%
    filter(AIRLINE %in% c("AA", "DL", "UA", "US")) %>%
    filter(!is.na(MONTH), !is.na(DAY), !is.na(ARRIVAL_DELAY)) %>%
    group_by(MONTH, DAY, AIRLINE) %>%
    summarise(n_total = n(), n_atrasos = sum(ARRIVAL_DELAY > 10), .groups = "drop")
}

col_spec <- cols_only(
  MONTH = col_integer(),
  DAY = col_integer(),
  AIRLINE = col_character(),
  ARRIVAL_DELAY = col_double()
)

stats_acumuladas <- read_csv_chunked(
  file = "flights.csv.zip",
  callback = DataFrameCallback$new(getStats),
  chunk_size = 100000,
  col_types = col_spec
)

```

4.

```

computeStats <- function(df_stats) {
  df_stats %>%
    group_by(AIRLINE, MONTH, DAY) %>%
    summarise(
      total_atrasos = sum(n_atrasos),
      total_voos = sum(n_total),
      .groups = "drop"
    ) %>%
    transmute(
      Cia = AIRLINE,
      Data = as.Date(paste(2015, MONTH, DAY, sep = "-")),
      Perc = total_atrasos / total_voos
    )
}

stats_finais <- computeStats(stats_acumuladas)

```

5.

```

library(lubridate)

```


Anexando pacote: 'lubridate'

Os seguintes objetos são mascarados por 'package:base':

date, intersect, setdiff, union


```
pal <- scale_fill_gradient(
  low = "#4575b4",
  high = "#d73027",
  name = "Perc. Atrasos",
  labels = scales::percent_format(accuracy = 1)
)
baseCalendario <- function(stats, cia) {
  df_sub <- stats %>%
    filter(Cia == cia) %>%
    mutate(
      Mes = month(Data, label = TRUE, abbr = TRUE,
        locale = "pt_BR.UTF-8"),
      DiaSemana = wday(Data, label = TRUE, abbr = TRUE, week_start = 7,
        locale = "pt_BR.UTF-8"),
      SemanaDoMes = ceiling((day(Data) + wday(floor_date(Data, "month")) - 1) / 7)
    )
  ggplot(df_sub, aes(x = SemanaDoMes, y = factor(DiaSemana, levels = rev(levels(DiaSemana))),
    fill = Perc)) +
    geom_tile(color = "white", linewidth = 0.3) +
    facet_wrap(~ Mes, ncol = 3, scales = "free_x") +
    scale_y_discrete() +
    theme_minimal() +
    theme(
      panel.grid = element_blank(),
      axis.text.x = element_blank(),
      axis.ticks = element_blank(),
      strip.background = element_rect(fill = "grey95", color = NA),
      strip.text = element_text(face = "bold")
    ) +
    labs(x = NULL, y = NULL)
}
cAA <- baseCalendario(stats_finais, "AA")
cDL <- baseCalendario(stats_finais, "DL")
cUA <- baseCalendario(stats_finais, "UA")
```

```
cUS <- baseCalendario(stats_finais, "US")
cAA + pal + ggtitle("Percentual de Atrasos em 2015 - American Airlines (AA)")
```




```
cDL + pal + ggtitle("Percentual de Atrasos em 2015 - Delta Air Lines (DL)")
```

Percentual de Atrasos em 2015 – Delta Air Lines (DL)




```
cUA + pal + ggtitle("Percentual de Atrasos em 2015 – United Airlines (UA)")
```

Percentual de Atrasos em 2015 – United Airlines (UA)



```
cUS + pal + ggtitle("Percentual de Atrasos em 2015 - US Airways (US)")
```



```
Sys.setenv(TZ = "America/Sao_Paulo")
Sys.time()
```

```
[1] "2026-08-24 19:09:30 -03"
```