Lab09

Tiago Perroni - 281972

```
import pandas as pd
import matplotlib.pyplot as plt
from plotnine import (
    ggplot, aes, geom_point, geom_smooth, scale_x_log10, scale_y_log10,
    facet_wrap, facet_grid, labs, theme_minimal, theme, element_text)
from plotnine.data import diamonds

cut_order = ["Fair", "Good", "Very Good", "Premium", "Ideal"]
color_order = ["J", "I", "H", "G", "F", "E", "D"]
clarity_order = ["I1", "SI2", "SI1", "VS2", "VS1", "VVS2", "VVS1", "IF"]

diamonds['cut'] = pd.Categorical(diamonds['cut'], categories=cut_order, ordered=True)
diamonds['color'] = pd.Categorical(diamonds['color'], categories=color_order, ordered=True)
diamonds['clarity'] = pd.Categorical(diamonds['clarity'], categories=clarity_order, ordered=

diamonds.head()
```

	carat	cut	color	clarity	depth	table	price	x	y	z
0	0.23	Ideal	E	SI2	61.5	55.0	326	3.95	3.98	2.43
1	0.21	Premium	E	SI1	59.8	61.0	326	3.89	3.84	2.31
2	0.23	Good	E	VS1	56.9	65.0	327	4.05	4.07	2.31
3	0.29	Premium	I	VS2	62.4	58.0	334	4.20	4.23	2.63
4	0.31	Good	J	SI2	63.3	58.0	335	4.34	4.35	2.75

```
plot_2 = (
    ggplot(diamonds, aes(x='carat', y='price'))
    + geom_point(alpha=0.08, size=0.5, color='#2c3e50')
    + geom_smooth(method='lowess', color='#e74c3c', size=1)
    + scale_x_log10()+ scale_y_log10()
    + labs(
        title="Relação entre Peso (Carat) e Preço (USD) dos Diamantes",
```

```
        x="Peso em Quilates (escala log10)",
        y="Preço em USD (escala log10)")
    + theme_minimal())
plot_2
```

```
<plotnine.ggplot.ggplot object at 0x0000023A1B2328B0>
```

Ações tomadas para garantir a qualidade do gráfico:

Com 53.940 observações, o gráfico de dispersão padrão viraria uma mancha preta. Aplicou-se transparência severa (alpha=0.08) e tamanho de ponto reduzido (size=0.5). Como carat e price possuem distribuições com forte assimetria à direita e comportamento exponencial, a conversão para escala logarítmica lineariza a relação e explicita variações percentuais. Adicionou-se uma curva não paramétrica para capturar a tendência média sem sobrecarregar a visualização.

Achados:

Existe uma forte associação positiva e exponencial entre o peso (carat) e o preço (price) dos diamantes, à medida que o peso aumenta, o valor comercial cresce desproporcionalmente devido à raridade de pedras maiores. Ao aplicar a transformação logarítmica em ambos os eixos, a relação assume um comportamento predominantemente linear, confirmando que aumentos percentuais no peso resultam em aumentos percentuais constantes no preço.

```
plot_3 = (
    ggplot(diamonds, aes(x='carat', y='price', color='cut'))
    + geom_point(alpha=0.04, size=0.4)
    + geom_smooth(method='lm', se=False, size=1)
    + scale_x_log10() + scale_y_log10()
    + facet_wrap('~cut', nrow=1)
    + labs(
        title="Relação Preço vs. Peso por Qualidade de Corte",
        x="Peso em Quilates (escala log10)",
        y="Preço em USD (escala log10)")
    + theme_minimal()
    + theme(legend_position='none'))
plot_3
```

```
<plotnine.ggplot.ggplot object at 0x0000023A18933DD0>
```

Achados:

A relação positiva entre preço e peso se mantém constante em todos os tipos de corte, no entanto, nota-se que diamantes com cortes de melhor qualidade partem de um nível base de

preço ligeiramente superior para um mesmo peso em relação a cortes inferiores. A inclinação das retas de regressão linear nas escalas logarítmicas é muito similar entre as categorias, demonstrando que a taxa de valorização em função do peso não sofre grandes alterações estruturais isoladamente pelo tipo de corte.

```
plot_4 = (
    ggplot(diamonds, aes(x='carat', y='price', color='clarity'))
    + geom_smooth(method='lm', se=False, size=0.8)
    + scale_x_log10() + scale_y_log10()
    + facet_grid('color ~ cut')
    + labs(
        title="Tendência de Preço vs. Peso por Corte, Cor e Clareza",
        x="Peso em Quilates (escala log10)",
        y="Preço em USD (escala log10)",
        color="Clareza")
    + theme_minimal() + theme(
        strip_text=element_text(size=8),
        axis_text=element_text(size=6)))
plot_4
```

```
<plotnine.ggplot.ggplot object at 0x0000023A1B2616D0>
```

Dificuldades encontradas:

Ao tentar analisar simultaneamente 5 níveis de corte, 7 cores e 8 graus de clareza, surge o desafio da alta dimensionalidade pois são 280 combinações possíveis. Plotar os dados brutos de dispersão de todos os 280 grupos gera poluição visual e impede a interpretação. Para contornar esse problema, removeu-se os pontos individuais e manteve-se apenas as linhas de tendência (linear geom_smooth(method=‘lm’)) organizadas em uma grade de painéis (facet_grid(‘color ~ cut’)), utilizando cores para mapear a clareza.

Achados:

A relação positiva de crescimento de preço conforme o peso é consistente em praticamente todas as 280 combinações. Contudo, o patamar absoluto de preço e a inclinação mudam consideravelmente: a clareza e a cor exercem um impacto multiplicador marcante sobre o preço por quilate. Diamantes com combinações de cor superior e máxima clareza apresentam retas de preço significativamente mais deslocadas para cima em relação a diamantes de cor fraca e baixa clareza, mostrando que a pureza e a cor da pedra intensificam o prêmio cobrado por quilates adicionais.

```
Sys.setenv(TZ = "America/Sao_Paulo")
Sys.time()
```

```
[1] "2026-10-21 16:25:39 -03"
```